

ESCUELA COLOMBIANA DE INGENIERÍA JULIO GARAVITO
DEPARTAMENTO DE INGENIERÍA DE SISTEMAS

PROYECTO PTIA PRIETO - RUIZ

Proyecto de curso PTIA

HITO 1

Grupo 01

Integrantes:

Nicolas Prieto, William Santiago Ruiz

Fecha de entrega: 29 - 08 - 2026

Declaración firmada

"Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación"

Nombre del estudiante y Firma:

William Santiago Ruiz Medina

Fecha: 29 de 08 de 2026

<Nicolas Prieto>

Fecha: 29 de 08 de 2026

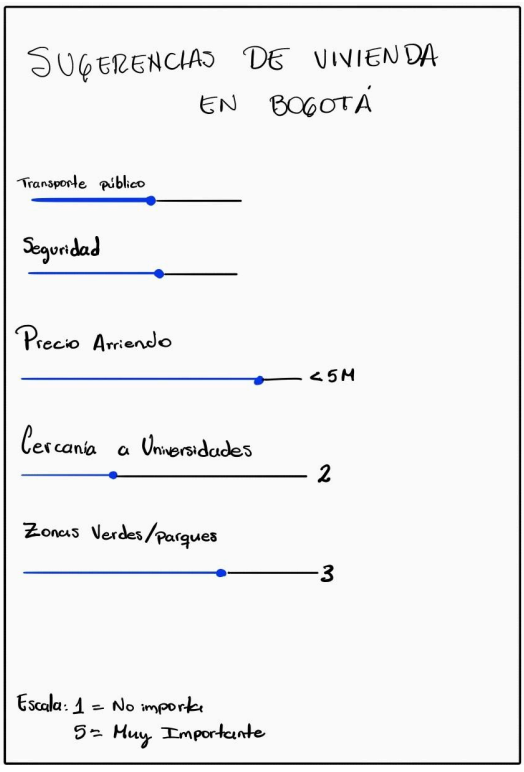
Índice de contenido

1. **INTRODUCCIÓN**
2. **TRABAJOS RELACIONADOS**
3. **DESCRIPCIÓN DEL PROBLEMA**
4. **JUSTIFICACIÓN**

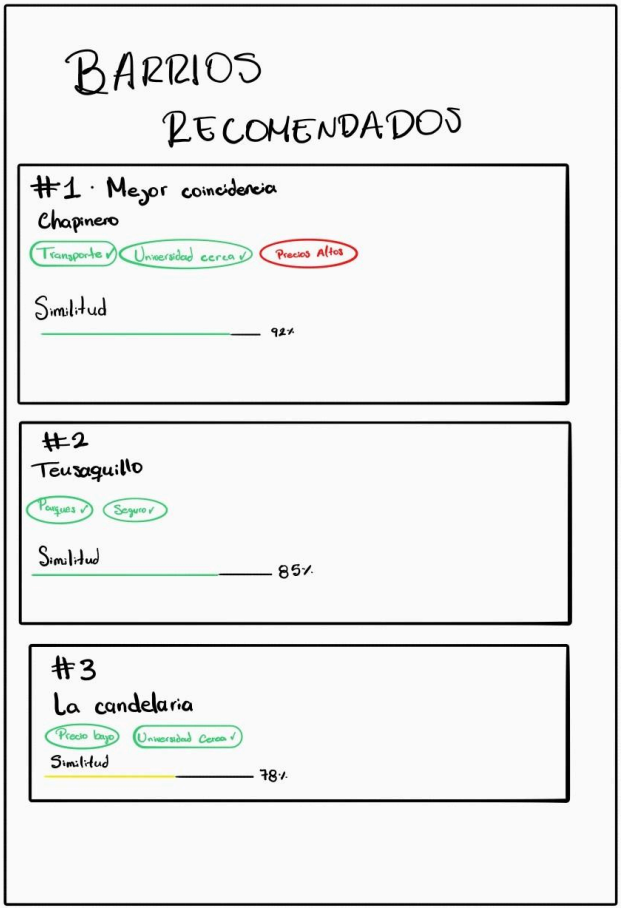
Índice de Tablas

Índice de figuras

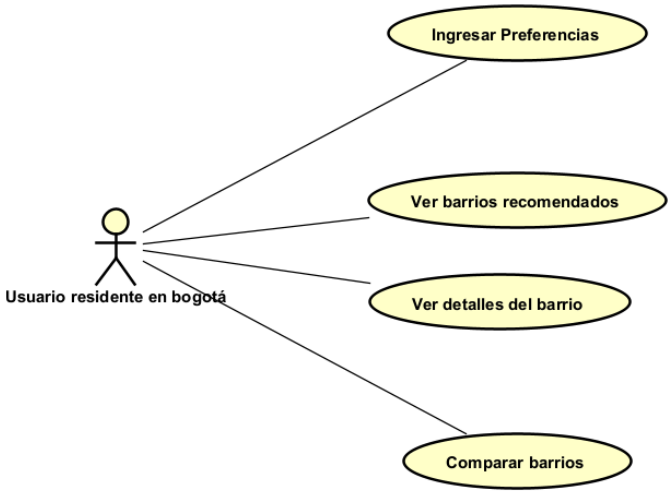
1. *Figura 1: A*



2. *Figura 2:*



3. *Figura 3: Diagrama inicial de casos de uso para un residente de bogotá (Target del programa)*



1. Introducción

Recomendaciones

Definición de los problemas

- ¿Cuáles serían tres problemas que les interesaría resolver?
- ¿Por qué como proyecto de PTIA?

Problemas que nos interesa resolver:

1. Un estudiante que no logra saber qué electiva técnica o humanística debería cursar en un próximo semestre

2. Una persona que quiere mudarse de ciudad o de barrio y no logra encontrar un barrio que se acomode a sus necesidades y gustos

3. Un estudiante universitario con bajo rendimiento académico constante durante varios semestres que no logra subir su promedio y está en riesgo la continuación y finalización en su pregrado.

Por qué como proyecto de PTIA:

- Se decidió que estas problemáticas son relevantes para la materia ya que se pueden implementar soluciones basadas en aprendizaje automático supervisado, como por ejemplo KNN usando un dataset para todos los casos ya que cumplen con esa característica común

2. Trabajos relacionados

Recomendaciones

Definir el estado del arte

- ¿Cuáles son dos trabajos relacionados a cada problema? (resultados y tecnología)

1.1 A Course Recommender System Built on Success to Support Students at Riskin Higher Education

- Paper académico publicado en revista indexada de minería de datos educativos. El sistema recomendador usa KNN para ayudar a los estudiantes a elegir qué cursos tomar antes de comenzar el semestre: recomienda los cursos que la mayoría de los vecinos más cercanos con historial exitoso han aprobado. Los vecinos más cercanos son estudiantes que, en la misma etapa de sus estudios, han reprobado o aprobado casi los mismos cursos con calificaciones iguales o muy similares. Usan k=5 vecinos y las features son cursos y calificaciones anteriores.

- Relevancia: es exactamente la misma lógica del proyecto, perfil académico de entrada, recomendación de curso como salida, KNN como motor.

1.2 https://doi.org/10.11648/j.ijdsa.20190506.14

- Paper que presenta un método el cual desarrolla un sistema de filtrado colaborativo que recomienda electivas a estudiantes de pregrado basándose en sus notas en cursos previos relacionados. Usa KNN para descubrir relaciones ocultas entre los cursos que los estudiantes han aprobado en el pasado y las electivas disponibles actualmente. El dataset es real, con resultados académicos de estudiantes, y el modelo supera resultados previos en la literatura.

- Relevancia: Usa KNN y el problema es casi el mismo al presentado

2.1 The Use of Machine Learning in Real Estate Research

- Artículo académico publicado en una revista indexada (MDPI). El estudio usa 24,317 registros de transacciones inmobiliarias reales en Hong Kong para comparar tres algoritmos de machine learning: Extra Trees, KNN y Random Forest, contra el modelo estadístico tradicional (regresión hedónica). Los features del dataset son características físicas de las propiedades: área en metros cuadrados, piso, antigüedad del edificio, acceso a transporte masivo y precio. KNN alcanzó un R^2 de 0.90 en el conjunto de prueba, superando ampliamente al modelo estadístico tradicional. Conclusión del paper: los algoritmos de ML, incluyendo KNN, son significativamente más precisos para predecir valores inmobiliarios basados en atributos de la propiedad y su entorno.

- Relevancia para el proyecto de barrios: valida que KNN funciona con variables de contexto urbano (transporte, ubicación, características físicas) para hacer predicciones sobre propiedades

2.2 https://www.academia.edu/37195157

- Proyecto aplicado que desarrolla un sistema de recomendación de propiedades para inversionistas del mercado inmobiliario del Reino Unido. Usa web scraping con Scrapy para recolectar datos de Zoopla (portal de propiedades), y aplica KNN con pesos por feature (feature-weighted KNN) junto con regresión para predecir precios de arriendo. El dataset incluye número de habitaciones, ubicación y otros atributos de cada propiedad. El sistema alcanzó una precisión aproximada del 95% para propiedades estándar, con una tasa de error promedio del 4.2% cuando k=3.

- Relevancia para el proyecto de barrios: dado un perfil de preferencias del usuario, el sistema busca propiedades similares mediante KNN y hace una recomendación.

3.1 1909.07444

- Paper académico de la Universidad de Mekelle (Etiopía). Desarrolla un modelo de predicción de rendimiento estudiantil para cinco materias (Inglés, Matemáticas, Física, Química y Biología) en colegios de secundaria. Usa KNN, SVM, Random Forest y MLP como clasificadores base, entrenados con datos reales recolectados de tres colegios mediante reportes académicos y encuestas. El problema se modela como clasificación binaria por materia: pasa o reprueba. Los features incluyen notas de periodos anteriores, datos demográficos y factores sociales del estudiante.

- Relevancia para el predictor académico: mismo dominio (rendimiento estudiantil), mismo tipo de clasificación (pasa/reprueba), mismo algoritmo entre los evaluados (KNN). Da respaldo académico formal para justificar el enfoque.

3.2 GitHub - nrepesh/Student-Performance-KNN · GitHub

- Repositorio de implementación práctica de KNN para predecir la calificación final (G3) de estudiantes de secundaria usando el dataset público de 2 estudiantes de la UCI, que incluye notas parciales G1 y G2, horas de estudio, ausencias, consumo de alcohol y datos familiares. El proyecto construye pipelines de preprocesamiento y compara tres métricas de distancia: Manhattan (L1), Euclidiana (L2) y Chebyshev (L∞), buscando el k óptimo para cada una. El modelo final clasifica a un nuevo estudiante (Bob.csv) usando los vecinos más cercanos del conjunto de entrenamiento.

- Relevancia para el predictor académico: misma tecnología (KNN en Python), mismo dominio, dataset estructurado con variables académicas como entrada y nota final como salida.

3. Descripción del problema

Recomendaciones

- ¿Cuáles criterios van a usar para seleccionar el problema a resolver?
- ¿Cuál es el problema seleccionado?

- **PROBLEMA SELECCIONADO:**
  - Una persona que quiere mudarse de ciudad o de barrio y no logra encontrar un barrio que se acomode a sus necesidades y gustos

  A veces cuando una persona se muda de ciudad o de barrio, no logra encontrar ni definir parámetros para una búsqueda de su nuevo hogar, pues debe tener en cuenta varias cosas, como lo pueden ser el colegio de los hijos en caso de tenerlos, cercanía al transporte público, precios que se ajusten a su presupuesto, garajes en ciertos casos, cercanía al trabajo, etc etc; La persona puede terminar tomando decisiones en base a opiniones y sugerencias de familiares o amigos dejando el criterio y la toma de decisiones a terceros y tomando una decisión final muy sesgada.

- **CRITERIOS:**
  Impacto sobre un problema real: Todo el mundo en alguna etapa de su vida se ve obligado a buscar vivienda, ya sea para compra o arriendo, por lo que afecta a todos.

  Dataset ampliamente construible y escabale: Los datos de barrios y precios, se pueden conseguir a través de diferentes portales web como el DANE, y portales de vivienda como metrocuadrado y finca raíz, así mismo es altamente escalable pues si se quisiera aplicar en otras ciudades simplemente se debería ampliar el dataset con la misma información de las mismas fuentes pero de otras ciudades.

  KNN altamente aplicable: El algoritmo de KNN se puede usar con relativa facilidad aquí si consideramos que una vivienda es un punto en un espacio (conjunto) y características, el usuario con sus parámetros busca al vecino más cercano en este espacio dado su perfil

4. Justificación

Recomendaciones

- ¿Cuál es el gran problema que se quiere resolver?
- ¿Por qué es importante resolverlo?

PROBLEMA PRINCIPAL:

- Las personas que buscan dónde vivir en una ciudad como Bogotá no cuentan con una herramienta que traduzca su estilo de vida en una recomendación concreta de barrio. La búsqueda actual suele ser manual, desordenada y sesgada: se basa en precio, en lo que alguien conocido recomienda, o en lo que aparece primero en un portal inmobiliario. Variables críticas como seguridad, acceso a transporte, cercanía a colegios o al trabajo, y disponibilidad de parqueadero raramente se evalúan en conjunto y de forma objetiva.

  El gran problema es que tomar una mala decisión de vivienda tiene consecuencias costosas e irreversibles en el corto plazo: un contrato de arriendo de 12 meses en un barrio que no se adapta a las necesidades reales de la persona o familia genera estrés, gastos de mudanza repetidos, pérdida de tiempo en desplazamientos y reducción en la calidad de vida.

  La inteligencia artificial puede resolver esto: dado un perfil de preferencias del usuario, un sistema basado en KNN puede encontrar los barrios cuyas características objetivas más se aproximan a ese perfil, convirtiendo una decisión subjetiva y desordenada en una recomendación estructurada, explicable y personalizada.

JUSTIFICACIÓN:

- En este caso, Bogotá es una ciudad de más de 8 millones de habitantes con una alta movilidad residencial: personas que llegan de otras ciudades, familias que cambian de estrato, estudiantes universitarios que buscan independizarse, trabajadores que cambian de empleo y necesitan acortar su desplazamiento. Todos enfrentan el mismo proceso desordenado de búsqueda de vivienda.

  El problema importa por tres razones concretas:

- Económica. Una mala elección de barrio implica costos directos: multas por rompimiento anticipado de contrato, gastos de mudanza, y en muchos casos meses de arriendo pagados en una zona que no funciona para la persona. En Bogotá, donde el arriendo promedio oscila entre $800.000 y $2.500.000 COP según el sector, equivocarse tiene un costo real y medible.
- De calidad de vida. Vivir lejos del trabajo o del colegio de los hijos incrementa el tiempo de desplazamiento diario, que en Bogotá ya es uno de los más altos de América Latina. Un barrio mal elegido afecta directamente el bienestar, la salud y la productividad de las personas.

- De acceso a información. Las herramientas actuales (portales inmobiliarios, grupos de Facebook, recomendaciones de conocidos) no procesan preferencias de forma objetiva ni personalizada. Existe una oportunidad clara para que la inteligencia artificial llene ese vacío, democratizando el acceso a una recomendación de calidad que hoy solo tienen quienes conocen bien la ciudad o pueden pagar un asesor inmobiliario